

Repaso de Probabilidad (2)

Lección 06

Dr. Pablo Alvarado Moya

CE5506 Introducción al reconocimiento de patrones
Área de Ingeniería en Computadores
Tecnológico de Costa Rica

II Semestre, 2019

Contenido

- 1 Dos variables aleatorias
 - Distribuciones conjuntas y marginales
 - Distribuciones condicionales
 - Operadores

- 2 Múltiples variables

Funciones de distribución acumulada conjunta y marginal

- Sean X e Y variables aleatorias.
- Las variables por separado tienen distribuciones acumuladas $F_X(x)$ y $F_Y(y)$
- **Distribución acumulada conjunta** representa relación entre las dos variables:

$$F_{XY}(x,y) = P(X \leq x, Y \leq y)$$

- La relación entre la CDF acumulada y las separadas es

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x,y)$$

$$F_Y(y) = \lim_{x \rightarrow \infty} F_{XY}(x,y)$$

- En este contexto $F_X(x)$ y $F_Y(y)$ son las funciones de distribución acumuladas **marginales** de $F_{XY}(x,y)$

Propiedades de CDF conjunta

- $0 \leq F_{XY}(x,y) \leq 1$
- $\lim_{x,y \rightarrow \infty} F_{XY}(x,y) = 1$
- $\lim_{x,y \rightarrow -\infty} F_{XY}(x,y) = 0$
- $F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x,y)$

Funciones de masa de probabilidad conjunta y marginal (1)

- Sean X e Y dos variables aleatorias **discretas**
- La función de masa de probabilidad conjunta $p_{XY} : \mathbb{R} \times \mathbb{R} \rightarrow [0,1]$ es:

$$p_{XY}(x,y) = P(X = x, Y = y)$$

- $0 \leq P_{XY}(x,y) \leq 1$ para todo x e y
- $\sum_{x \in \text{val}(X)} \sum_{y \in \text{val}(Y)} P_{XY}(x,y) = 1$
- La función de masa de probabilidad marginal de X es

$$p_X(x) = \sum_{y \in \text{val}(Y)} p_{XY}(x,y)$$

Funciones de masa de probabilidad conjunta y marginal (2)

- La función de masa de probabilidad marginal de Y es

$$p_Y(y) = \sum_{x \in \text{val}(X)} p_{XY}(x, y)$$

- **Marginalización:** formar distribución marginal con respecto a una variable, eliminando la otra variable por medio de la suma

Funciones de densidad de probabilidad conjunta y marginal (1)

- Sean X e Y variables aleatorias continuas con función de distribución acumulada conjunta F_{XY} (continua y suave)
- La función de densidad de probabilidad conjunta es:

$$f_{XY}(x,y) = \frac{\partial^2 F_{XY}(x,y)}{\partial x \partial y}$$

- Se cumple que

$$\iint_{(x,y) \in A} f_{XY}(x,y) dx dy = P((X,Y) \in A)$$

- **¡Cuidado!** $f_{XY}(x,y) \neq P(X = x, Y = y)$

Funciones de densidad de probabilidad conjunta y marginal (2)

- $f_{XY}(x,y) \geq 0$. Puede ser mayor que uno (¡densidad!)
- Se debe cumplir

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{XY}(x,y) dx dy = 1$$

- Marginalización en el caso continuo se realiza con

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x,y) dy$$


que es la función de densidad de probabilidad **marginal** (o **densidad marginal**) de X .

Funciones de densidad de probabilidad conjunta y marginal

(3)

- La marginalización de Y resulta en

$$f_Y(y) = \int_{-\infty}^{\infty} f_{XY}(x,y) dx$$



Distribuciones condicionales

- Distribución condicional busca cuál es la distribución de probabilidad de Y , cuando sabemos que X debe tomar un cierto valor.
- El caso discreto, la función de masa de probabilidad condicional de Y dado X es (se asume $p_X(x) \neq 0$)

$$p_{Y|X}(y|x) = \frac{p_{XY}(x,y)}{p_X(x)}$$

- El caso continuo, la función de densidad de probabilidad condicional de Y dado X es (por analogía)

$$f_{Y|X}(y|x) = \frac{f_{XY}(x,y)}{f_X(x)}$$

con $f_X(x) \neq 0$

Regla de Bayes

- Caso de variables aleatorias discretas

$$P_{Y|X}(y|x) = \frac{P_{XY}(x,y)}{P_X(x)} = \frac{P_{X|Y}(x|y)P_Y(y)}{\sum_{y' \in \text{val}(Y)} P_{X|Y}(x|y')P_Y(y')}$$

- Caso de variables aleatorias continuas

$$f_{Y|X}(y|x) = \frac{f_{XY}(x,y)}{f_X(x)} = \frac{f_{X|Y}(x|y)f_Y(y)}{\int_{-\infty}^{\infty} f_{X|Y}(x|y')f_Y(y') dy'}$$

Regla de Bayes

Nombres de las partes

- En general, forma de la regla de Bayes es:

$$p(a \mid b) = \frac{p(b \mid a)p(a)}{p(b)}$$

- $p(a \mid b)$ es la probabilidad **a posteriori**,
- $p(b \mid a)$ es valor de **verosimilitud** (o *likelihood*)
- $p(a)$ es la probabilidad **a priori**
- $p(b)$ constante de normalización.

Ejemplo de aplicación de regla de Bayes

Ejemplo: mapas de probabilidad de color

Mapas de probabilidad de color

- **Problema:** encontrar en imagen lugares con objetos de color específico (p. ej. piel).
- Proceso de formación: color depende de iluminación, objeto y sensor
⇒ variación impredecible de colores
- **Solución:** usar entrenamiento de un “modelo de color” que cubra cambios esperados.
- Defínanse dos clases: *objeto* y $\neg \text{objeto}$.
- Generar canal con probabilidad de que cada píxel pertenezca a *objeto* o a $\neg \text{objeto}$, de acuerdo únicamente a su color.

Modelos de probabilidad

- Se estima la probabilidad de que un determinado color c forma parte del objeto con dos **histogramas** de datos de entrenamiento:

$$p(c \mid \text{objeto})$$

$$p(c \mid \neg \text{objeto})$$

- Se busca $p(\text{objeto} \mid c)$ con regla de Bayes

Probabilidad de ser objeto

- Para caso de probabilidad de ser objeto por su color:

$$p(\text{objeto} \mid c) = \frac{p(c \mid \text{objeto})p(\text{objeto})}{p(c)}$$

y utilizando las reglas de probabilidad se conoce que

$$p(c) = p(c \mid \text{objeto})p(\text{objeto}) + p(c \mid \neg \text{objeto})p(\neg \text{objeto})$$

donde además $p(\neg \text{objeto}) = 1 - p(\text{objeto})$.

Ejemplo



Independencia

(1)

- Dos variables aleatorias X e Y son **independientes** si

$$F_{XY}(x,y) = F_X(x)F_Y(y)$$

para todo valor de x e y

- Para variables discretas
 - $p_{XY}(x,y) = p_X(x)p_Y(y) \quad \forall x \in \text{val}(X), \forall y \in \text{val}(Y)$
 - $p_{Y|X}(y|x) = p_Y(y)$ si $p_X(x) \neq 0, \forall y \in \text{val}(Y)$
- Para variables continuas
 - $f_{XY}(x,y) = f_X(x)f_Y(y) \quad \forall x \in \mathbb{R}, \forall y \in \mathbb{R}$
 - $f_{Y|X}(y|x) = f_Y(y)$ si $f_X(x) \neq 0, \forall y \in \mathbb{R}$

Independencia

(2)

- Si X e Y son independientes entonces para cualesquiera subconjuntos $A, B \subseteq \mathbb{R}$

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

- Si X e Y son independientes, entonces también lo serán **funciones** de X e Y

Esperanza y covarianza

(1)

- Esperanza de X, Y discretas:

$$E[g(X, Y)] \stackrel{!}{=} \sum_{x \in \text{val}(X)} \sum_{y \in \text{val}(Y)} g(x, y) p_{XY}(x, y)$$

- Esperanza de X, Y continuas:

$$E[g(X, Y)] \stackrel{!}{=} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f_{XY}(x, y) dx dy$$

- La **covarianza** expresa la relación de dos variables aleatorias:

$$\text{Cov}[X, Y] \stackrel{!}{=} E[(X - E[X])(Y - E[Y])]$$

- Observe que $\text{Cov}[X, X] = \text{Var}[X]$

Esperanza y covarianza

(2)

- De modo similar que para la varianza se demuestra que

$$\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

- Si $\text{Cov}[X, Y] = 0$ entonces X e Y están **decorreladas**

Propiedades

- Linealidad:

$$E[af(X, Y) + bg(X, Y)] = a E[f(X, Y)] + b E[g(X, Y)]$$

- $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y] + 2 \text{Cov}[X, Y]$
- Si X e Y son independientes entonces $\text{Cov}[X, Y] = 0$
- Si X e Y son independientes, entonces
 $E[f(X)g(Y)] = E[f(X)] E[g(Y)]$

Múltiples variables

Propiedades básicas

Caso de PDF

(1)

- Función de distribución acumulada conjunta de X_1, X_2, \dots, X_n

$$F_{X_1, X_2, \dots, X_n} = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

- Función de densidad de probabilidad conjunta de X_1, \dots, X_n

$$f_{X_1, X_2, \dots, X_n}(x_1, \dots, x_n) = \frac{\partial^n F_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n)}{\partial x_1 \dots \partial x_n}$$

- Función de densidad de probabilidad marginal

$$f_{X_1}(X_1) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_{X_1, X_2, \dots, X_n}(x_1, \dots, x_n) dx_2 \dots dx_n$$

Propiedades básicas

Caso de PDF

(2)

- Función de densidad de probabilidad condicional

$$f_{X_1|X_2,\dots,X_n}(x_1|x_2,\dots,x_n) = \frac{f_{X_1,X_2,\dots,X_n}(x_1,x_2,\dots,x_n)}{f_{X_2,\dots,X_n}(x_2,\dots,x_n)}$$

- Probabilidad de evento $A \subseteq \mathbb{R}^n$

$$P((x_1,\dots,x_n) \in A) = \int_{(x_1,\dots,x_n) \in A} f_{X_1,\dots,X_n}(x_1,\dots,x_n) dx_1 \dots dx_n$$

Regla de la cadena

- De probabilidades condicionales multivarias se demuestra que:

$$\begin{aligned} f(x_1 \dots x_n) &= f(x_n | x_1, \dots, x_{n-1}) f(x_1, \dots, x_{n-1}) \\ &= f(x_n | x_1, \dots, x_{n-1}) f(x_{n-1} | x_1, \dots, x_{n-2}) f(x_1, \dots, x_{n-2}) \\ &= f(x_1) \prod_{i=2}^n f(x_i | x_1 \dots x_{i-1}) \end{aligned}$$

Independencia

- Para múltiples eventos $A_1 \dots A_k$ se dicen ser **mutualmente independientes** si para cualquier subconjunto $S \subseteq \{1, 2, \dots, k\}$ se tiene

$$P(\cap_{i \in S} A_i) = \prod_{i \in S} P(A_i)$$

- Las variables aleatorias $X_1 \dots X_n$ son independientes si

$$f(X_1, \dots, X_n) = f(X_1)f(X_2) \dots f(X_n)$$

Vectores aleatorios

(1)

- Todas las derivaciones anteriores se pueden extender a vectores
- Se habla entonces de vectores aleatorios

$$\underline{\mathbf{X}} = [X_1 \quad X_2 \quad \dots \quad X_n]^T$$

- Puesto que $X : \Omega \rightarrow \mathbb{R}$ entonces $\underline{\mathbf{X}} : \Omega \rightarrow \mathbb{R}^n$
- Esperanza con $g : \mathbb{R}^n \rightarrow \mathbb{R}$

$$\mathbb{E}[g(\underline{\mathbf{X}})] = \int_{\mathbb{R}^n} g(\underline{\mathbf{x}}) f_{\underline{\mathbf{X}}}(\underline{\mathbf{x}}) d\underline{\mathbf{x}}$$

Matriz de covarianza

$$\begin{aligned}\Sigma &= \begin{bmatrix} \text{Cov}[X_1, X_1] & \cdots & \text{Cov}[X_1, X_n] \\ \vdots & \ddots & \vdots \\ \text{Cov}[X_n, X_1] & \cdots & \text{Cov}[X_n, X_n] \end{bmatrix} \\ &= E[\underline{\mathbf{X}}\underline{\mathbf{X}}^T] - E[\underline{\mathbf{X}}]E[\underline{\mathbf{X}}]^T\end{aligned}$$

- La matriz de covarianza es semidefinida positiva
- La matriz de covarianza es simétrica

Resumen

- 1 Dos variables aleatorias
 - Distribuciones conjuntas y marginales
 - Distribuciones condicionales
 - Operadores

- 2 Múltiples variables

Este documento ha sido elaborado con software libre incluyendo \LaTeX , Beamer, GNUPlot, GNU/Octave, XFig, Inkscape, GNU-Make y Subversion en GNU/Linux



Este trabajo se encuentra bajo una Licencia Creative Commons Atribución-NoComercial-LicenciarIgual 3.0 Unported. Para ver una copia de esta Licencia, visite <http://creativecommons.org/licenses/by-nc-sa/3.0/> o envíe una carta a Creative Commons, 444 Castro Street, Suite 900, Mountain View, California, 94041, USA.

© 2017–2019 Pablo Alvarado-Moya Área de Ingeniería en Computadores Instituto Tecnológico de Costa Rica