

Análisis de factores

Lección 20

Dr. Pablo Alvarado Moya

CE5506 Introducción al reconocimiento de patrones
Área de Ingeniería en Computadores
Tecnológico de Costa Rica

II Semestre, 2019

Contenido

- 1 Matrices de covarianza singulares
- 2 Condicionales y marginales de gaussianas
- 3 Modelo de análisis de factores
- 4 EM para análisis de factores

El caso de menos datos que dimensiones

- Hasta ahora hemos supuesto suficientes datos m para estimar n parámetros en mezcla de gaussianas.
- No tendremos ningún problema si $m \gg n$.
- En escenarios donde $n \gg m$ es incluso complicado modelar los datos con un solo gaussiano, así que una mezcla de gaussianos es una tarea imposible
- El problema principal es que el espacio engendrado por m datos tendrá a lo sumo $\min(m, n)$ dimensiones.

Singularidad de covarianza

- Si estimamos los parámetros de máxima verosimilitud

$$\underline{\mu} = \frac{1}{m} \sum_{i=1}^m \underline{\mathbf{x}}^{(i)} \quad \underline{\Sigma} = \frac{1}{m} \sum_{i=1}^m (\underline{\mathbf{x}}^{(i)} - \underline{\mu})(\underline{\mathbf{x}}^{(i)} - \underline{\mu})^T$$

con $n \gg m$ la matriz $\underline{\Sigma}$ resulta singular, lo que imposibilita la evaluación la densidad gaussiana.

- Este caso $n \gg m$ **confina** los datos a un subespacio de m dimensiones, lo que en principio hace improbable que un dato en n dimensiones *viva* en ese subespacio.
- Podemos imponer restricciones a $\underline{\Sigma}$ para evitar singularidad.
- Usar el modelo de análisis de factores ofrecerá una alternativa.

Restringiendo la matriz de covarianza

(1)

- Podemos imponer alineamiento con los ejes.
- Esto implica que Σ es diagonal con

$$\Sigma_{jj} = \frac{1}{m} \sum_{i=1}^m (x_j^{(i)} - \mu_j)^2$$

- Si alguno de los elementos en la diagonal es cero, tampoco sirve esta matriz
- Una restricción más fuerte es definir $\Sigma = \sigma^2 \mathbf{I}$ con

$$\sigma^2 = \frac{1}{mn} \sum_{j=1}^n \sum_{i=1}^m (x_j^{(i)} - \mu_j)^2$$

cuyas superficies equiprobables corresponden a esferas.

Restringiendo la matriz de covarianza

(2)

- Σ completa requiere $m \geq n + 1$ para una estimación (posiblemente) no singular.
- Con restricciones requerimos $m \geq 2$.

Distribuciones gaussianas multivariadas conjuntas

- Supongamos que tenemos una variable aleatoria vectorial

$$\underline{\mathbf{x}} = \begin{bmatrix} \underline{\mathbf{x}}_1 \\ \underline{\mathbf{x}}_2 \end{bmatrix}$$

con $\underline{\mathbf{x}}_1 \in \mathbb{R}^r$, $\underline{\mathbf{x}}_2 \in \mathbb{R}^s$, and $\underline{\mathbf{x}} \in \mathbb{R}^{r+s}$

- Supongamos que $\underline{\mathbf{x}} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}, \boldsymbol{\Sigma})$ con

$$\underline{\boldsymbol{\mu}} = \begin{bmatrix} \underline{\boldsymbol{\mu}}_1 \\ \underline{\boldsymbol{\mu}}_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}$$

con $\underline{\boldsymbol{\mu}}_1 \in \mathbb{R}^r$, $\underline{\boldsymbol{\mu}}_2 \in \mathbb{R}^s$, $\boldsymbol{\Sigma}_{11} \in \mathbb{R}^{r \times r}$, $\boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21}^T \in \mathbb{R}^{r \times s}$,
 $\boldsymbol{\Sigma}_{22} \in \mathbb{R}^{s \times s}$.

Distribución marginal


- Si $\underline{\mathbf{x}}_1$ y $\underline{\mathbf{x}}_2$ son conjuntamente gaussianos multivariados, ¿cuál es la distribución de $\underline{\mathbf{x}}_1$?
- Se cumple $E[\underline{\mathbf{x}}_1] = \underline{\boldsymbol{\mu}}_1$
- La relación entre las covarianzas:

$$\begin{aligned}\text{Cov}(\underline{\mathbf{x}}) &= \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} = E[(\underline{\mathbf{x}} - \underline{\boldsymbol{\mu}})(\underline{\mathbf{x}} - \underline{\boldsymbol{\mu}})^T] \\ &= E \left[\begin{pmatrix} \underline{\mathbf{x}}_1 - \underline{\boldsymbol{\mu}}_1 \\ \underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2 \end{pmatrix} \begin{pmatrix} \underline{\mathbf{x}}_1 - \underline{\boldsymbol{\mu}}_1 \\ \underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2 \end{pmatrix}^T \right] \\ &= E \begin{bmatrix} (\underline{\mathbf{x}}_1 - \underline{\boldsymbol{\mu}}_1)(\underline{\mathbf{x}}_1 - \underline{\boldsymbol{\mu}}_1)^T & (\underline{\mathbf{x}}_1 - \underline{\boldsymbol{\mu}}_1)(\underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2)^T \\ (\underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2)(\underline{\mathbf{x}}_1 - \underline{\boldsymbol{\mu}}_1)^T & (\underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2)(\underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2)^T \end{bmatrix}\end{aligned}$$

de donde se obtienen las equivalencias con $\boldsymbol{\Sigma}_{ij}$.

Marginales de una gaussiana

- Puesto que la distribución marginal de una gaussiana es a su vez gaussiana entonces $\underline{\mathbf{x}}_1 \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_1, \boldsymbol{\Sigma}_{11})$



Distribución condicional

- ¿Cuál es la distribución condicional de $\underline{\mathbf{x}}_1$ dado $\underline{\mathbf{x}}_2$?
- Se puede demostrar con

$$p(\underline{\mathbf{x}}_1|\underline{\mathbf{x}}_2) = \frac{p(\underline{\mathbf{x}}_1, \underline{\mathbf{x}}_2)}{p(\underline{\mathbf{x}}_2)} \quad \begin{array}{l} \leftarrow \mathcal{N}(\underline{\boldsymbol{\mu}}, \underline{\boldsymbol{\Sigma}}) \\ \leftarrow \mathcal{N}(\underline{\boldsymbol{\mu}}_2, \underline{\boldsymbol{\Sigma}}_{22}) \end{array}$$

que $\underline{\mathbf{x}}_1|\underline{\mathbf{x}}_2 \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_{1|2}, \underline{\boldsymbol{\Sigma}}_{1|2})$, con

$$\begin{aligned}\underline{\boldsymbol{\mu}}_{1|2} &= \underline{\boldsymbol{\mu}}_1 + \underline{\boldsymbol{\Sigma}}_{12} \underline{\boldsymbol{\Sigma}}_{22}^{-1} (\underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2) \\ \underline{\boldsymbol{\Sigma}}_{1|2} &= \underline{\boldsymbol{\Sigma}}_{11} - \underline{\boldsymbol{\Sigma}}_{12} \underline{\boldsymbol{\Sigma}}_{22}^{-1} \underline{\boldsymbol{\Sigma}}_{21}\end{aligned}$$

Modelo de análisis de factores

- En el modelo de análisis de factores postulamos la distribución conjunta en $(\underline{\mathbf{x}}, \underline{\mathbf{z}})$ con $\underline{\mathbf{x}} \in \mathbb{R}^n$, la variable aleatoria latente $\underline{\mathbf{z}} \in \mathbb{R}^k$, $k < n$, como

$$\begin{aligned}\underline{\mathbf{z}} &\sim \mathcal{N}(\underline{\mathbf{0}}, \mathbf{I}) \\ \underline{\mathbf{x}} | \underline{\mathbf{z}} &\sim \mathcal{N}(\underline{\boldsymbol{\mu}} + \mathbf{\Lambda} \underline{\mathbf{z}}, \boldsymbol{\Psi})\end{aligned}$$

- Parámetros: $\underline{\boldsymbol{\mu}} \in \mathbb{R}^n$, $\mathbf{\Lambda} \in \mathbb{R}^{n \times k}$, $\boldsymbol{\Psi} = \text{diag}(\underline{\boldsymbol{\psi}}) \in \mathbb{R}^{n \times n}$, eligiendo $k < n$.
- Note que la variable latente $\underline{\mathbf{z}}$ es ahora continua

Interpretación

- Cada punto $\underline{\mathbf{x}}^{(i)}$ se genera en varios pasos
- Primero se muestrea $\underline{\mathbf{z}}^{(i)} \in \mathbb{R}^k$ de gaussiano multivariado
- Luego $\underline{\mathbf{z}}^{(i)}$ se mapea de forma afín con $\underline{\boldsymbol{\mu}} + \boldsymbol{\Lambda}\underline{\mathbf{z}}^{(i)}$
- Finalmente $\underline{\mathbf{x}}^{(i)}$ se genera sumando ruido gaussiano de covarianza $\boldsymbol{\Psi}$

$$\underline{\mathbf{z}} \sim \mathcal{N}(\underline{\mathbf{0}}, \mathbf{I})$$

$$\underline{\boldsymbol{\varepsilon}} \sim \mathcal{N}(\underline{\mathbf{0}}, \boldsymbol{\Psi})$$

$$\underline{\mathbf{x}} = \underline{\boldsymbol{\mu}} + \boldsymbol{\Lambda}\underline{\mathbf{z}} + \underline{\boldsymbol{\varepsilon}}$$

con $\underline{\boldsymbol{\varepsilon}}$ y $\underline{\mathbf{z}}$ independientes.

- Las variables aleatorias $\underline{\mathbf{z}}$ y $\underline{\mathbf{x}}$ tienen una distribución gaussiana conjunta

$$\begin{bmatrix} \underline{\mathbf{z}} \\ \underline{\mathbf{x}} \end{bmatrix} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_{\mathbf{zx}}, \boldsymbol{\Sigma})$$

- Las variables aleatorias \underline{z} y \underline{x} tienen una distribución gaussiana conjunta

$$\begin{bmatrix} \underline{z} \\ \underline{x} \end{bmatrix} \sim \mathcal{N}(\underline{\mu}_{zx}, \underline{\Sigma})$$

- Necesitamos encontrar $\underline{\mu}_{zx}$ y $\underline{\Sigma}$.
- Puesto que $\underline{z} \sim \mathcal{N}(\underline{0}, \underline{I})$ entonces $E[\underline{z}] = \underline{0}$
- La esperanza de \underline{x}

$$E[\underline{x}] = E[\underline{\mu} + \underline{\Lambda}\underline{z} + \underline{\varepsilon}] = \underline{\mu} + \underline{\Lambda} E[\underline{z}] + E[\underline{\varepsilon}] = \underline{\mu}$$

- Por esta razón:

$$\underline{\mu}_{zx} = \begin{bmatrix} \underline{0} \\ \underline{\mu} \end{bmatrix}$$

Covarianza por bloques

- Para encontrar Σ necesitamos calcular

$$\Sigma_{zz} = E[(\underline{z} - E[\underline{z}])(\underline{z} - E[\underline{z}])^T] \quad \text{superior izquierdo}$$

$$\Sigma_{zx} = E[(\underline{z} - E[\underline{z}])(\underline{x} - E[\underline{x}])^T] \quad \text{superior derecho}$$

$$\Sigma_{xx} = E[(\underline{x} - E[\underline{x}])(\underline{x} - E[\underline{x}])^T] \quad \text{inferior derecho}$$

- Puesto que $\underline{z} \sim \mathcal{N}(\underline{0}, \mathbf{I})$ entonces $\Sigma_{zz} = \text{Cov}(\underline{z}) = \mathbf{I}$
- Para Σ_{zx} , con $\text{Cov}(\underline{z}) = E[\underline{z}\underline{z}^T] = \mathbf{I}$ porque $E[\underline{z}] = \underline{0}$

$$\begin{aligned} E[(\underline{z} - E[\underline{z}])(\underline{x} - E[\underline{x}])^T] &= E[\underline{z}(\underline{\mu} + \Lambda \underline{z} + \underline{\varepsilon} - \underline{\mu})^T] \\ &= \underbrace{E[\underline{z}\underline{z}^T]}_{\mathbf{I}} \Lambda^T + \underbrace{E[\underline{z}\underline{\varepsilon}^T]}_{0 \text{ por independencia}} = \Lambda^T \end{aligned}$$

Bloque Σ_{xx}

- Para el último término Σ_{xx}

$$\begin{aligned}
 \Sigma_{xx} &= E \left[(\underline{x} - E[\underline{x}])(\underline{x} - E[\underline{x}])^T \right] \\
 &= E \left[(\underline{\mu} + \underline{\Lambda}\underline{z} + \underline{\varepsilon} - \underline{\mu})(\underline{\mu} + \underline{\Lambda}\underline{z} + \underline{\varepsilon} - \underline{\mu})^T \right] \\
 &= E \left[\underline{\Lambda}\underline{z}\underline{z}^T \underline{\Lambda}^T + \underline{\varepsilon}\underline{z}^T \underline{\Lambda}^T + \underline{\Lambda}\underline{z}\underline{\varepsilon}^T + \underline{\varepsilon}\underline{\varepsilon}^T \right] \\
 &= \underline{\Lambda} E[\underline{z}\underline{z}^T] \underline{\Lambda}^T + E[\underline{\varepsilon}\underline{\varepsilon}^T] \\
 &= \underline{\Lambda}\underline{\Lambda}^T + \underline{\Psi}
 \end{aligned}$$

Distribución conjunta y marginal

- Agrupando todos los resultados anteriores:

$$\begin{bmatrix} \underline{\mathbf{z}} \\ \underline{\mathbf{x}} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \underline{\mathbf{0}} \\ \underline{\boldsymbol{\mu}} \end{bmatrix}, \begin{bmatrix} \mathbf{I} & \boldsymbol{\Lambda}^T \\ \boldsymbol{\Lambda} & \boldsymbol{\Lambda}\boldsymbol{\Lambda}^T + \boldsymbol{\Psi} \end{bmatrix} \right)$$

- La distribución marginal de $\underline{\mathbf{x}} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}\boldsymbol{\Lambda}^T + \boldsymbol{\Psi})$
- Dado un conjunto de entrenamiento $\{\underline{\mathbf{x}}^{(i)}; i = 1, \dots, m\}$ la verosimilitud logarítmica es:

$$\ell(\underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}, \boldsymbol{\Psi}) = \ln \prod_{i=1}^m \frac{1}{(2\pi)^{n/2} |\boldsymbol{\Sigma}_{xx}|^{1/2}} e^{(-\frac{1}{2}(\underline{\mathbf{x}}^{(i)} - \underline{\boldsymbol{\mu}})^T \boldsymbol{\Sigma}_{xx}^{-1} (\underline{\mathbf{x}}^{(i)} - \underline{\boldsymbol{\mu}}))}$$

- La estimación de máxima verosimilitud maximiza lo anterior respecto a sus parámetros, pero no se puede hacer fácilmente, por lo que requerimos de nuevo el algoritmo EM.

EM para análisis de factores

- Paso E

Encuentre $Q_i(\underline{\mathbf{z}}^{(i)}) = p(\underline{\mathbf{z}}^{(i)} | \underline{\mathbf{x}}^{(i)}; \underline{\boldsymbol{\theta}})$

- Paso M

$$\underline{\boldsymbol{\theta}} = \arg \max_{\underline{\boldsymbol{\theta}}} \sum_i \int_{\underline{\mathbf{z}}^{(i)}} Q_i(\underline{\mathbf{z}}^{(i)}) \ln \left(\frac{p(\underline{\mathbf{x}}^{(i)}, \underline{\mathbf{z}}^{(i)}; \underline{\boldsymbol{\theta}})}{Q_i(\underline{\mathbf{z}}^{(i)})} \right) d\underline{\mathbf{z}}^{(i)}$$

Paso E

(1)

- Paso E es relativamente simple de derivar.
- Necesitamos $Q_i(\underline{\mathbf{z}}^{(i)}) = p(\underline{\mathbf{z}}^{(i)} | \underline{\mathbf{x}}^{(i)}; \underline{\boldsymbol{\mu}}, \underline{\boldsymbol{\Lambda}}, \underline{\boldsymbol{\Psi}})$
- Considerando que

$$\begin{bmatrix} \underline{\mathbf{z}} \\ \underline{\mathbf{x}} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \underline{\mathbf{0}} \\ \underline{\boldsymbol{\mu}} \end{bmatrix}, \begin{bmatrix} \mathbf{I} & \underline{\boldsymbol{\Lambda}}^T \\ \underline{\boldsymbol{\Lambda}} & \underline{\boldsymbol{\Lambda}} \underline{\boldsymbol{\Lambda}}^T + \underline{\boldsymbol{\Psi}} \end{bmatrix} \right)$$

y además que $\begin{bmatrix} \underline{\mathbf{x}}_1 \\ \underline{\mathbf{x}}_2 \end{bmatrix}$ tiene $\underline{\mathbf{x}}_1 | \underline{\mathbf{x}}_2 \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_{1|2}, \underline{\boldsymbol{\Sigma}}_{1|2})$, con

$$\begin{aligned} \underline{\boldsymbol{\mu}}_{1|2} &= \underline{\boldsymbol{\mu}}_1 + \underline{\boldsymbol{\Sigma}}_{12} \underline{\boldsymbol{\Sigma}}_{22}^{-1} (\underline{\mathbf{x}}_2 - \underline{\boldsymbol{\mu}}_2) \\ \underline{\boldsymbol{\Sigma}}_{1|2} &= \underline{\boldsymbol{\Sigma}}_{11} - \underline{\boldsymbol{\Sigma}}_{12} \underline{\boldsymbol{\Sigma}}_{22}^{-1} \underline{\boldsymbol{\Sigma}}_{21} \end{aligned}$$

Paso E

(2)

entonces

$$\underline{\mathbf{z}}^{(i)} | \underline{\mathbf{x}}^{(i)}; \underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}, \boldsymbol{\Psi} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}}, \boldsymbol{\Sigma}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}})$$

donde

$$\underline{\boldsymbol{\mu}}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}} = \boldsymbol{\Lambda}^T (\boldsymbol{\Lambda} \boldsymbol{\Lambda}^T + \boldsymbol{\Psi})^{-1} (\underline{\mathbf{x}}^{(i)} - \underline{\boldsymbol{\mu}})$$

$$\boldsymbol{\Sigma}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}} = \mathbf{I} - \boldsymbol{\Lambda}^T (\boldsymbol{\Lambda} \boldsymbol{\Lambda}^T + \boldsymbol{\Psi})^{-1} \boldsymbol{\Lambda}$$

con lo que

$$Q_i(\underline{\mathbf{z}}^{(i)}) = \frac{1}{\sqrt{(2\pi)^k |\boldsymbol{\Sigma}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}}|}} e^{\left(-\frac{1}{2} (\underline{\mathbf{z}}^{(i)} - \underline{\boldsymbol{\mu}}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}})^T \boldsymbol{\Sigma}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}}^{-1} (\underline{\mathbf{z}}^{(i)} - \underline{\boldsymbol{\mu}}_{\mathbf{z}^{(i)} | \mathbf{x}^{(i)}}) \right)}$$

Paso M

(1)

- El paso M requiere maximizar

$$\begin{aligned}
 & \sum_{i=1}^m \int_{\underline{\mathbf{z}}^{(i)}} Q_i(\underline{\mathbf{z}}^{(i)}) \ln \frac{p(\underline{\mathbf{x}}^{(i)}, \underline{\mathbf{z}}^{(i)}; \underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}, \boldsymbol{\Psi})}{Q_i(\underline{\mathbf{z}}^{(i)})} d\underline{\mathbf{z}}^{(i)} \\
 &= \sum_{i=1}^m \mathbb{E}_{\underline{\mathbf{z}}^{(i)} \sim Q_i} \left[\ln \frac{p(\underline{\mathbf{x}}^{(i)}, \underline{\mathbf{z}}^{(i)}; \underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}, \boldsymbol{\Psi})}{Q_i(\underline{\mathbf{z}}^{(i)})} \right] \\
 &= \sum_{i=1}^m \mathbb{E}_{\underline{\mathbf{z}}^{(i)} \sim Q_i} \left[\ln p(\underline{\mathbf{x}}^{(i)} | \underline{\mathbf{z}}^{(i)}; \underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}, \boldsymbol{\Psi}) \right] + \mathbb{E}_{\underline{\mathbf{z}}^{(i)} \sim Q_i} \left[\ln \frac{p(\underline{\mathbf{z}}^{(i)}; \underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}, \boldsymbol{\Psi})}{Q_i(\underline{\mathbf{z}}^{(i)})} \right]
 \end{aligned}$$

con respecto a $\underline{\boldsymbol{\mu}}, \boldsymbol{\Lambda}, \boldsymbol{\Psi}$

Paso M

(2)

- Después de la manipulación algebraica se maximiza en:

$$\underline{\mu} = \frac{1}{m} \sum_{i=1}^m \underline{\mathbf{x}}^{(i)}$$

$$\begin{aligned} \Phi = & \frac{1}{m} \sum_{i=1}^m \underline{\mathbf{x}}^{(i)} \underline{\mathbf{x}}^{(i)T} - \underline{\mathbf{x}}^{(i)} \underline{\mu}_{z^{(i)}|x^{(i)}}^T \Lambda^T - \Lambda \underline{\mu}_{z^{(i)}|x^{(i)}} \underline{\mathbf{x}}^{(i)T} \\ & + \Lambda (\underline{\mu}_{z^{(i)}|x^{(i)}} \underline{\mu}_{z^{(i)}|x^{(i)}}^T + \Sigma_{z^{(i)}|x^{(i)}}) \Lambda^T \end{aligned}$$

$$\Psi = \text{diag}(\Phi)$$

$$\Lambda = \left(\sum_{i=1}^m (\underline{\mathbf{x}}^{(i)} - \underline{\mu}) \underline{\mu}_{z^{(i)}|x^{(i)}}^T \right) \left(\sum_{i=1}^m \underline{\mu}_{z^{(i)}|x^{(i)}} \underline{\mu}_{z^{(i)}|x^{(i)}}^T + \Sigma_{z^{(i)}|x^{(i)}} \right)^{-1}$$

Resumen

- 1 Matrices de covarianza singulares
- 2 Condicionales y marginales de gaussianas
- 3 Modelo de análisis de factores
- 4 EM para análisis de factores

Este documento ha sido elaborado con software libre incluyendo \LaTeX , Beamer, GNUPlot, GNU/Octave, XFig, Inkscape, GNU-Make y Subversion en GNU/Linux



Este trabajo se encuentra bajo una Licencia Creative Commons Atribución-NoComercial-LicenciarIgual 3.0 Unported. Para ver una copia de esta Licencia, visite <http://creativecommons.org/licenses/by-nc-sa/3.0/> o envíe una carta a Creative Commons, 444 Castro Street, Suite 900, Mountain View, California, 94041, USA.

© 2017–2019 Pablo Alvarado-Moya Área de Ingeniería en Computadores Instituto Tecnológico de Costa Rica